

实验报告：IsaacLab 强化学习环境理解与 G1 步态分析

12211637 黄梓烁

内容板块：Part A. 原理理解部分 (Q1-Q8)

一、模块一：任务入口与配置流转

1.1 任务注册 (gym.register) 机制解析 (Q1)

在 IsaacLab 的任务注册机制中，`gym.register(...)` 的各字段承担了将环境逻辑、物理配置与算法超参数解耦并路由的功能：

1. **id**: 任务的全局唯一标识符（如 Unitree-G1-29dof-Velocity）。在**训练和展示时**，用户通过命令行参数（`--task`）指定该 ID，系统据此检索并加载所有关联配置。
2. **entry_point**: 指定环境实例化的底层管理类（通常为 `ManagerBasedRLEnv`）。它是 RL 闭环的**核心执行者**，负责统筹物理引擎推进、传感器数据采集及奖励计算。
3. **env_cfg_entry_point**: 指向训练环境配置文件（`RobotEnvCfg`）。**训练时**被调用，负责定义大规模并行环境（如 4096 个）、复杂随机地形及完整的训练奖励函数。
4. **play_env_cfg_entry_point**: 指向测试展示配置文件（`RobotPlayEnvCfg`）。**展示/推理时**被调用，基于训练配置进行轻量化微调，以适应可视化需求。
5. **rsl_rl_cfg_entry_point**: 算法超参数配置入口（`BasePPORunnerCfg`）。由 **PPO 算法库**直接管理，定义神经网络架构、学习率、折扣因子及采样批次等纯算法层面的参数。

1.2 训练与展示环境配置的差异分析 (Q2)

`RobotPlayEnvCfg` 继承自 `RobotEnvCfg` 并重写了部分参数，这是为了满足模型部署和可视化阶段的特殊需求：

1. **使用更少的并行环境数 (num_envs)**: 训练阶段依赖海量并行环境（如 4096）以保障梯度的稳定性和样本多样性；而展示阶段仅需验证单体或少量机器人的行为（如 32 个），减少 `num_envs` 可极大降低显存占用与 CPU 渲染负担。
2. **使用更小的地形规模 (terrain 行列数)**: 训练时需要大规模、多梯度的随机地形提供泛化场景；展示阶段仅需局部舞台供机器人运动，缩小规模能显著缩短仿真加载时间并聚焦观察视野。

3. **使用更宽的命令范围 (limit_ranges):** 训练初期为保证探索稳定性，通常会限制速度指令范围（配合课程学习）；但在展示阶段，为了测试策略的极限运动能力与泛化性能，会放开全范围的速度指令输入（即将 ranges 替换为 limit_ranges）。

二、模块二：从 RL 闭环理解环境配置

2.1 观测空间设计与 Sim-to-Real 原理 (Q3)

策略网络 (PolicyCfg) 与价值网络 (CriticCfg) 观测项的差异体现了**非对称 Actor-Critic 架构**的核心思想：

1. **Critic 的“特权信息”:** Critic 仅参与仿真训练阶段，它能够直接获取物理引擎底层的精确数据 (Privileged Information)，如精确的绝对线速度、外部扰动力、地形高度扫描及摩擦系数等。这些“上帝视角”信息使其能更精准地评估状态价值，加速模型收敛。
2. **Policy 的传感器局限:** Policy 网络最终需部署于物理真机。真机无法获知绝对坐标或精确摩擦力，只能依赖 IMU 和关节编码器获取带有噪声的相对状态量（如角速度、相对位置）。因此 Policy 的观测项必须严格限制在真机传感器可采集的范围内。
3. **Sim-to-Real 关系:** 通过这种非对称设计，拥有特权信息的 Critic 可以在训练时高效指导 Policy，迫使 Policy 仅依赖带噪声的局部信息学出鲁棒的控制策略，从而有效跨越仿真与现实的鸿沟 (Sim-to-Real Gap)。

2.2 动作空间缩放与控制安全性 (Q4)

在 ActionsCfg 中采用 JointPositionAction 并设置 scale=0.25 具有重要的工程意义：

1. **网络输出范围:** 神经网络 (Policy) 的最终输出通常经过归一化或激活函数（如 Tanh），数值被限制在 **[-1.0, 1.0]** 的无量纲区间内，以保证梯度传播的稳定。
2. **scale=0.25 的控制意义:** 该比例因子作为乘数，将网络的归一化输出映射为实际的物理控制量。即网络输出 1.0 时，代表关节目标角度在默认基础姿态 (Default Offset) 上偏移 0.25 弧度（约 14.3 度）。
3. **相对控制（残差控制）的优势:** 相比让网络直接输出关节的绝对角度（容易导致初始阶段大范围乱动），采用“基础位姿 + 缩放残差”的相对控制方式，将机器人的探索空间安全地约束在标称姿态附近，有效防止训练初期因动作突变导致的仿真崩溃或真机硬件损坏。

2.3 核心任务奖励项解析 (Q5)

在 RewardsCfg 中，最直接驱动机器人完成“走路”任务目标的奖励项是：

1. **track_lin_vel_xy**: 鼓励机器人在 XY 水平面上精准追踪用户下发的线速度指令，是实现多向移动的核心驱动力。
2. **track_ang_vel_z**: 鼓励机器人精准追踪绕 Z 轴的偏航角速度指令，是实现转向行为的核心驱动力。

2.4 多目标约束奖励的必要性 (Q6)

如果仅保留速度跟踪奖励，RL 智能体极易陷入“奖励黑客 (Reward Hacking)”，演化出不自然或破坏性的步态。必须引入以下约束：

1. **能耗与动作惩罚 (energy, action_rate)**: 缺乏该项，机器人会通过高频剧烈的关节抖动来榨取速度，导致动作疯狂且在现实中极易烧毁电机。
2. **姿态稳定性约束 (flat_orientation_l2, base_height)**: 缺乏该项，机器人可能会为了防摔而采取重心极低的“匍匐”或身体严重倾斜的怪异前行方式。
3. **关节安全约束 (dof_pos_limits)**: 缺乏该项，关节可能频繁折跃至物理死区，在真机上会直接摧毁机械结构。
4. **足端行为约束 (feet_slide, feet_clearance)**: 缺乏该项，仿真环境中最省力的移动方式往往是足端不离地的“滑冰”或“拖行”。必须通过惩罚滑动和奖励抬腿，强制其学习符合生物力学的迈步特征。

2.5 域随机化 (Domain Randomization) 机制 (Q7)

EventCfg 中的随机化项旨在提升策略的泛化与抗干扰能力：

1. **初始化参数随机化 (摩擦、质量)**: 模拟真实世界中地面材质的差异（如大理石、草地）及机器人负载分布的误差。强制网络不依赖单一物理常数，学习通用的物理规律。
2. **周期性推扰动 (push_robot)**: 模拟现实中不可预测的动态干扰（如路人碰撞、风力、电机瞬时误差），迫使机器人掌握在动态失稳中快速恢复平衡的本能反射。
3. **鲁棒性提升**: 经历大规模随机化洗礼后的策略，能够应对物理部署时广泛存在的未建模动态 (Unmodeled Dynamics)，实现 Zero-shot（零样本）的真机迁移。

2.6 终止条件与课程学习的作用 (Q8)

这两项机制直接决定了强化学习的样本效率与训练稳定性：

提前终止 (Early Termination, 如 `bad_orientation`, `base_height`):

样本效率: 避免在机器人已摔倒、无法恢复的无效状态下浪费大量仿真步数。

训练稳定性: 切断了智能体通过“倒地后蠕动”获取微弱速度奖励的可能，防止策略陷入局部最优。

课程学习 (Curriculum, 如 `terrain_levels`, `lin_vel_cmd_levels`):

样本效率与稳定性: 若初始阶段即采用复杂地形与极限速度，未训练的智能体会持续跌倒，导致奖励极度稀疏 (Reward Sparsity)，模型无法起步。课程学习采取“从平地慢走起步，随能力动态增加难度”的策略，确保优化梯度始终平稳连续，大幅提升了最终收敛的成功率和上限。

PART.B 实验设计部分

1. 我选择了哪个实验选项

本次实验我选择了 选项 B: 减弱/取消足端滑动惩罚 (Foot Slide Penalty)，以此来观察奖励函数中的约束项对机器人最终生成步态的决定性影响。

2. 我改了哪个参数

在 `velocity_env_cfg.py` 配置文件中，我定位到了 `RewardsCfg` (奖励配置) 类。将其中的 `feet_slide` (足端滑动惩罚) 的权重系数 (`weight`) 由原先的 `-0.2` 修改为了 `0.0`。这意味着在整个训练过程中，环境不再对机器人足端与地面接触时的相对滑动速度进行扣分惩罚。

3. 改动前我的预测是什么

在取消该惩罚项之前，我预测策略网络 (Policy Network) 会发生典型的“奖励黑客 (Reward Hacking)”现象。具体表现为：

机器人将放弃正常的“抬腿-腾空-迈步-落地”这一拟人化/生物学步态。

机器人会演化出一种类似“穿滑板鞋”的双脚或多脚贴地滑行/拖地前行的步态。

尽管动作极不自然，但我预测它在 `track_lin_vel_xy` (线速度跟踪) 上的得分依然会很高，且极少发生跌倒 (高存活率)。

4. 我为什么这样预测

做出这一预测主要基于强化学习的优化逻辑与机器人动力学原理：

物理稳定性的诱惑： 在正常的行走步态中，机器人必须交替抬起足端（进入摆动相），这会瞬间减小支撑多边形（Polygon of Support）的面积，极易导致重心失稳而触发环境重置（如 bad_orientation 惩罚）。而“贴地滑行”能始终保持最大的支撑面积，是一种极其安全的静态平衡策略。


目标函数的最短路径： 强化学习算法（PPO）本质上是一个无情的数值优化器。本次任务的最高优先级奖励是“追踪目标线速度”。在没有 feet_slide 惩罚来规范足端摩擦学行为的情况下，最快、最省力且最不容易摔倒的加速方式，就是利用物理仿真器中的摩擦力直接“滑”向目标。

奖励塑形的必要性： 这反向说明了原版代码中加入 feet_slide 惩罚的必要性。纯粹的运动学目标无法内在地推导出生物学上的自然步态，必须通过多目标的精细约束（如惩罚足端滑动、惩罚过大的关节扭矩等），才能强行将策略网络从“物理捷径（局部最优）”中拉回到“拟人步态”的期望空间中。


PART C :

训练日志截图：

左 reward_feet_slide、右 reward_energy



左: reward_track_lin_vel_xy、右: mean_reward



PART D :

1. 实际现象是否符合我的预测?

总体在宏观物理层面上高度符合，但在微观得分机制上出现了意料之外的偏差。

符合预测的部分（宏观现象）：正如实验前所预测，在取消（0.0）或极大减弱（-0.05）足端滑动惩罚（feet_slide）后，为了追求最大化线速度并保持重心绝对稳定以避免跌倒，机器人完全放弃了生物学上正常的“抬腿-腾空-跨步”动作，演化出了极不自然的“贴地拖行/摩擦滑步”。这种步态使得 mean_episode_length（存活时间）和 track_lin_vel_xy（速度追踪奖励）均达到了极高的水平。

不符合预测的部分（微观偏差）：实验前我预测，由于采取了“拖地”步态，机器人将彻底破坏步态节律（gait），且无法获得足端抬起高度（feet_clearance）的奖励。但意外的是，TensorBoard 曲线显示，机器人在后期的 gait 和 feet_clearance 得分依然极高（甚至接近满分）。

2.可能受到了哪些其他奖励项或终止条件的影响?

这种“肉眼看似拖地，数据却拿满分”的偏差，深刻暴露了策略网络受到其他复杂奖励机制“裹挟”而产生的极度精妙的“奖励黑客”行为：

对 feet_clearance（抬腿高度）与 gait（步态节律）的极限欺骗：

为了在不摔倒的前提下同时拿满速度分和步态分，机器人并没有真正“贴死”在地上，而是演化出了一种“高频微幅蹭地/小碎步”。它将脚掌抬离地面的高度刚刚好越过代码中 clearance 的判定阈值（例如几毫米），并在极短的短时间内快速砸向地面以匹配 gait 的相位节律。在视觉上它在拖地，但在数学逻辑上，它完美骗过了这两个奖励项的检查。

被 energy（能耗）与 joint_acc（关节加速度）惩罚的反向印证：

这种高频蹭地摩擦需要电机输出极高的瞬间扭矩来克服地面阻力，这导致实验后期的 energy 和 joint_acc 惩罚项出现了断崖式的巨大跌幅。

受课程学习（Curriculum）目标速度的倒逼：

在实验后半段（引入 -0.05 惩罚后），目标指令速度（lin_vel_cmd_levels）急剧上升。策略网络经过权衡后认为：“即便采用摩擦步态会扣掉 -0.05 的滑动分和巨额的能量分，但只要能满足极高的速度追踪要求，总分（Total Reward）依然是净赚的。”

3. 这次实验让我对“奖励设计影响行为”有了什么认识？

1.神经网络是冷酷的“分数学者”，毫无物理常识。AI 不在乎人类期望的“美观”或“合理”，它只忠于最大化 Total Reward 的数学公式。如果不加以严苛的物理边界约束（如足够的 feet_slide 惩罚），它会毫不犹豫地寻找环境物理引擎的漏洞（如极端的摩擦学利用）来走捷径。

2.自然步态并非必然，而是多方惩罚相互制衡的“走钢丝”。拟人/拟态的正常行走，实际上是极其脆弱的局部平衡。取消任何一个看似边缘的约束项（如足端滑动），整个生物力学平衡就会瞬间崩塌，退化为低效、高耗能但得分高的畸形策略。

3.惩罚权重存在“阈值效应”与“路径依赖”。实验中将滑动惩罚从 0 恢复到 -0.05 后，机器人虽然出现了短暂的“戒断反应”（惩罚曲线小幅回升），但由于前期已经陷入了“拖地滑行”的局部最优解（Local Optima），且 -0.05 的惩罚力度不足以抵消高速追踪带来的诱惑，最终机器人选择“顶着惩罚继续作弊”。这证明了在奖励设计中，不仅各项权重需要精密调配，训练初期的引导环境对最终行为的定型也起着决定性作用。